

T.C.
DOKUZ EYLÜL ÜNİVERSİTESİ
EDEBİYAT FAKÜLTESİ
DİLBİLİMİ BÖLÜMÜ
LİSANS TEZİ

TÜRKÇE SÖZCÜK ANLAMI BELİRGİNLEŞTİRME
GÖREVLERİNDE VERİ ETİKETLEME
STRATEJİLERİNİN BERTURK MODELİ ÜZERİNDEN
İNCELENMESİ

Alper ARSLAN

Danışman
Prof.Dr. Özgün KOŞANER

2026

T.C.
DOKUZ EYLÜL ÜNİVERSİTESİ
EDEBİYAT FAKÜLTESİ
DİLBİLİMİ BÖLÜMÜ
LİSANS TEZİ

TÜRKÇE SÖZCÜK ANLAMI BELİRGİNLEŞTİRME
GÖREVLERİNDE VERİ ETİKETLEME
STRATEJİLERİNİN BERTURK MODELİ ÜZERİNDEN
İNCELENMESİ

Alper ARSLAN

Danışman
Prof.Dr. Özgün KOŞANER

İZMİR - 2026

YEMİN METNİ

Lisans Tezi olarak sunduğum “**Türkçe Sözcük Anlamı Belirginleştirme Görevlerinde Veri Etiketleme Stratejilerinin BERTURK Modeli Üzerinden İncelenmesi.**” adlı çalışmanın, tarafımdan, akademik kurallara ve etik değerlere uygun olarak yazıldığını ve yararlandığım eserlerin kaynakçada gösterilenlerden oluştuğunu, bunlara atıf yapılarak yararlanılmış olduğunu belirtir ve bunu onurumla doğrularım.

12.06.2026

Alper Arslan

ÖZET

Lisans Tezi

Türkçe Sözcük Anlamı Belirginleştirme Görevlerinde Veri Etiketleme Stratejilerinin Berturk Modeli Üzerinden İncelenmesi

Alper ARSLAN

Dokuz Eylül Üniversitesi

Edebiyat Fakültesi

Dilbilimi Bölümü

Doğal Dil İşleme (DDİ) alanının temel sorunlarından biri olan Sözcük Anlamı Belirginleştirme (SAB), Türkçe gibi anlamsal yelpazesi geniş dillerde oldukça zorlu bir görevdir. Alanyazındaki geleneksel yaklaşımlar, hedef sözcükleri çok geniş etiketlerle sınıflandırarak anlamsal aşırı yüklenmeye sebep olmaktadır. Bu çalışmanın amacı, Türkçe çokanlamlı sözcüklerin sözcük anlamı belirginleştirmesinde yüksek çözünürlüklü veri etiketleme stratejilerinin dönüştürücü tabanlı dil modelleri üzerindeki etkisini incelemektir. Araştırmada, Zipf'in anlam-sıklık kanunu temel alınarak ve Türkçe Ulusal Derlemi (TUD) verilerine göre kullanım sıklığı en yüksek çokanlamlı sözcükler arasından “yol”, “el”, “boğaz” ve “yüz” sözcükleri seçilmiştir. Hedef sözcükler BERT mimarisi üzerinde eğitilmiştir. Elde edilen bulgular, 5 dönemlik eğitim sonucunda modellerin doğrulama kayıplarında istikrarlı bir düşüş gerçekleştiğini ve bağlamsal örüntülerin ezberlenmek yerine öğrenilerek %80 üzeri bir başarı gösterdiği gözlemlenmiştir. Sonuç olarak, yapay zeka sistemlerinin Türkçedeki çokanlamlılık ve eşseslilik sorunlarını çözebilmesi için gelişmiş mimarilerin tek başına yeterli olmadığı; yüksek çözünürlüklü etiketleme stratejilerinin hedeflenen başarı için temel bir ön koşul olduğu kanıtlanmıştır.

Anahtar Kelimeler: Doğal Dil İşleme, Sözcük Anlamı Belirginleştirme, Çokanlamlılık, Eşseslilik, BERT Mimarisi, Veri Etiketleme Stratejileri

ABSTRACT
Bachelor's Thesis
An Analysis of Data Annotation Strategies For Turkish Word Sense
Disambiguation Tasks Using The Berturk Model
Alper ARSLAN

Dokuz Eylül University
Faculty of Letters
Department of Linguistics

Word Sense Disambiguation (WSD), one of the fundamental challenges in Natural Language Processing (NLP), is a highly demanding task in languages with broad semantic ranges like Turkish. Traditional approaches in the literature generally classify target words with broad tags such as "noun" or "verb," leading to semantic overload and significantly limiting model performance. The aim of this study is to investigate the impact of high-resolution data labeling strategies on transformer-based language models in the disambiguation of Turkish polysemous words. Within the scope of the research, based on Zipf's (1945) meaning-frequency law and the normalized frequency data from the Turkish National Corpus (TNC), four highly frequent polysemous words—"yol", "el", "boğaz", and "yüz"—were selected. The BERT architecture was fine-tuned using datasets prepared at a micro-level (with semantic sub-categories such as concrete/abstract) under human supervision. The findings indicate a consistent decrease in validation loss across 5 training epochs, with the models successfully learning contextual patterns rather than memorizing them, achieving high accuracy rates ranging from 80% to 98%. In conclusion, it has been demonstrated that advanced architectures alone are insufficient for AI systems to resolve polysemy and homonymy in Turkish; high-resolution labeling strategies are a fundamental prerequisite for the targeted success.

Keywords: Natural Language Processing, Word Sense Disambiguation, Polysemy, Homonymy, BERT Architecture, Data Labeling Strategies

**TÜRKÇE SÖZCÜK ANLAMI BELİRGİNLEŞTİRME GÖREVLERİNDE
VERİ ETİKETLEME STRATEJİLERİNİN BERTURK MODELİ
ÜZERİNDEN İNCELENMESİ**

İÇİNDEKİLER

YEMİN METNİ	iii
ÖZET	iv
ABSTRACT	v
İÇİNDEKİLER	vi
KISALTMALAR	viii
TABLolar LİSTESİ	ix
EKLER	x
BİRİNCİ BÖLÜM	1
GİRİŞ	1
1.1. ARAŞTIRMANIN ARKA PLANI VE PROBLEMİN TANIMI	1
1.2 ARAŞTIRMANIN AMACI	2
1.3 ARAŞTIRMA SORULARI VE HİPOTEZ	3
1.4. ARAŞTIRMANIN ÖNEMİ VE SINIRLILIKLARI	3
İKİNCİ BÖLÜM	5
KURAMSAL ÇERÇEVE VE ALANYAZIN TARAMASI	5
2.1. SÖZCÜK ANLAMI BELİRGİNLEŞTİRME NEDİR VE NASIL GELİŞMİŞTİR?	5
2.2 TÜRKÇENİN ANLAMSAL YAPISI VE ZİPF KANUNU	6
2.3 DOĞAL DİL İŞLEMEDE DERİN ÖĞRENME VE TRANSFORMER MİMARİLERİ	6
2.4 İLGİLİ ÇALIŞMALAR VE ARAŞTIRMANIN ALANYAZINDAKİ YERİ	7
ÜÇÜNCÜ BÖLÜM	9
ARAŞTIRMANIN YÖNTEMİ VE VERİSETİ	9
3.1. ARAŞTIRMANIN TASARIMI VE YAKLAŞIMI	9
3.2. VERİ SETİNİN HAZIRLANMASI VE SINIRLANDIRILMASI	9

3.2.1. Veri Kaynakları, Derlem Oluşturma ve Ön İşleme	10
3.2.2. Veri Etiketleme Süreci ve Doccano Platformunun Entegrasyonu.....	10
3.3 HESAPLAMALI MODEL: BERT _{Türk} MİMARİSİ.....	11
3.4. DENEYSEL KURULUM VE PARAMETRE OPTİMİZASYONU	11
3.5. DEĞERLENDİRME METRİKLERİ.....	12
DÖRDÜNCÜ BÖLÜM.....	13
BULGULAR.....	13
4.1. ARAŞTIRMA BULGULARINA GENEL BAKIŞ.....	13
4.2. “YOL” SÖZCÜĞÜNE İLİŞKİN BULGULAR.....	14
4.3. “EL” SÖZCÜĞÜNE İLİŞKİN BULGULAR.....	15
4.4. “BOĞAZ” SÖZCÜĞÜNE İLİŞKİN BULGULAR	16
4.5. “YÜZ” SÖZCÜĞÜNE İLİŞKİN BULGULAR VE ÇÖZÜNÜRLÜK ETKİSİ..	17
4.5.1. “Yüz” Sözcüğü Düşük Çözünürlüklü Etiketleme Aşaması (1. Aşama) ..	17
4.5.2. “Yüz” Sözcüğü Yüksek Çözünürlüklü Etiketleme Aşaması (2. Aşama)	18
4.6. HİPOTEZ TESTİ VE ARAŞTIRMA SORULARININ YANITLANMASI	20
BEŞİNCİ BÖLÜM.....	22
SONUÇ VE ÖNERİLER	22
KAYNAKÇA.....	24
EKLER	28

KISALTMALAR

BERT	Bidirectional Encoder Representations from Transformers
BERTurk	Bidirectional Encoder Representations from Transformers for Turkish
DDİ	Doğal Dil İşleme
GPT	Generative Pre-trained Transformer
JSONL	JavaScript Object Notation Lines
LlaMA	Large Language Model Meta AI
LLM	Large Language Models
MT	Machine Translation
NLP	Natural Language Processing
POS	Part of Speech
WSD	Word Sense Disambiguation
TNC	Turkish National Corpus
TUD	Türkçe Ulusal Derlemi

TABLÖLAR LİSTESİ

Tablo 1: Tüm Hedef Sözcükler İçin Karşılaştırmalı Model Performans Özeti Tablosu	13
Tablo 2: “Yol” Sözcüğü Karşılaştırmalı Performans Değerleri	14
Tablo 3: “El” Sözcüğü Karşılaştırmalı Performans Değerleri.....	15
Tablo 4: “Boğaz” Sözcüğü Karşılaştırmalı Performans Değerleri	16
Tablo 5: “Yüz” Sözcüğü 1. Aşama Model Performansı.....	18
Tablo 6: “Yüz” Sözcüğü 2. Aşama Model Performansı.....	19

EKLER

EK 1: BERT MİMARİSİ İNCE AYAR PYTHON BETİĞİ.....	1
EK 2: ETİKETLENMİŞ VERİ SETİ (JSONL) ÖRNEKLERİ	3
EK 3: VERİ İŞARETLEME ARACI (DOCCANO) ARAYÜZÜ VE ETİKETLEME SÜRECİ.....	4

BİRİNCİ BÖLÜM

GİRİŞ

İnsan dili, sadece bir iletişim aracı olmasının yanı sıra; dillerin doğası gereği durağanlıktan uzak, sürekli evrilen, esnek ve çok katmanlı bir bilişsel yapıdır. İnsanların birbirleriyle iletişimi sırasında sözcükler, bağlama, konuşucunun niyetine ve kültürel arka plana göre şekillenerek milyonlarca anlam kazanabilir. İnsan beyni bu anlamsal geçişleri ve belirsizlikleri saniyeler içinde ve neredeyse hiç çaba sarf etmeden çözümler. İşte bu karmaşık yapının bilgisayarlar tarafından anlaşılabilir ve işlenebilir hale getirilmesi, bilgisayar bilimlerinin en büyük sınavlarından biri olmuştur. Yirminci yüzyılın ortalarında makine çevirisi hayalleriyle başlayan *Doğal Dil İşleme* (İng. NLP) serüveni, günümüzde devasa olarak adlandırabileceğimiz metin yığınlarını saliseler içinde analiz edebilen çeşitli yapay zeka sistemlerine evrilmiştir.

Ancak bu teknolojik gelişme bile makinelerin, insan dilinin barındırdığı o anlamsal esnekliği anlamasının önündeki engelleri tam olarak ortadan kaldıramamıştır. Özellikle sondan eklemeli yapısı, zengin biçimbilimi ve esnek sözdizimi ile Türkçe gibi dillerde, sözcüklerin bağlama göre kazandığı farklı anlamları makine düzeyinde tespit etmek, bilgisayarlı dilbilim çalışmalarının merkezinde yer almaktadır. Bu tez çalışması, Türkçedeki anlamsal karmaşıklık, güncel derin öğrenme mimarilerinden biri olan BERT (Bidirectional Encoder Representations from Transformers) modeli (Schweter, 2020) üzerinden incelemekte ve sözcük anlamı belirsizliği sorununa, devasa ve karışık veriler yerine dilbilimsel olarak sınırları net çizilmiş nitelikli verilerle bir çözüm sunmayı amaçlamaktadır.

1.1. ARAŞTIRMANIN ARKA PLANI VE PROBLEMİN TANIMI

Doğal Dil İşleme alanındaki en uğraştırıcı sorunlardan biri olan *Sözcük Anlamı Belirginleştirme* (İng. Word Sense Disambiguation - WSD), bir metin veya tümce içerisinde geçen ve birden fazla anlamsal gönderimi olan (çokanlamlı veya eşsesli) bir sözcüğün, ilgili bağlamda hangi anlamıyla kullanıldığını otomatik olarak tespit etme işlemidir. Bu sorun, bilgisayarların insan dilini anlama kapasitesini doğrudan

etkilediği için alanyazında yapay zeka tarafından çözülmesi en zor olan sorunlardan biridir (Navigli, 2009).

Türkçenin doğası gereği sık kullanılan sözcüklerin anlamsal yelpazesi oldukça geniştir ve sözcük anlamı belirsizliği ise bu zenginliğin doğurduğu bir sonuçtur (Aydın vd., 2004). Bu durum, geleneksel kural tabanlı algoritmaların veya sözcükleri birbirinden bağımsız değerlendiren statik *sözcük gömme* (İng. word embedding) yöntemlerinin bağlamı öğrenmesinde yetersiz kalmasına sebep olmaktadır. Buna çözüm olarak, metin içindeki sözcüklerin hem sağındaki hem de solundaki bağlamı eşzamanlı olarak çözümleyebilen, *dönüştürücü* (İng. transformer) tabanlı çift yönlü dil modelleri problemin çözümü için yeni bir dönüm noktası yaratmıştır (Devlin vd., 2019). Ancak bu mimarilerin gücüne rağmen çözilemeyen sorunlar bu araştırmanın temel problem durumunu “Türkçedeki anlam belirsizliğinin geleneksel yöntemler ve düşük çözünürlüklü etiketleme stratejileriyle giderilmeye çalışılması yetersiz kalması” olarak belirlememize neden olmuştur. Du vd. (2019) tarafından yapılan çalışmada hedef sözcüklerin “isim” veya “eylem” gibi geniş şemsiye etiketlerle sınıflandırılması, birbirine zıt olan etiketleri sıkıştırarak anlamsal aşırı yüklenmeye yol açmıştır. Özetle, alanyazındaki mevcut yapay zeka modelleri ne kadar gelişmiş olursa olsun, anlamsal sınırlar insan gözetiminde mikro düzeyde netleştirilmediği sürece sistemlerin performansı ciddi ölçüde sınırlı kalmaktadır.

1.2 ARAŞTIRMANIN AMACI

Bu tezin temel amacı, Türkçede yüksek oranda *çokanlamlılık* (İng. polysemy) ve *eşseslilik* (İng. homonymy) barındıran hedef sözcüklerin (“yol”, “el”, “boğaz”, “yüz”) doğru anlamlarının, ön eğitilmiş bir Türkçe dil modeli olan BERTurk kullanılarak yüksek doğrulukla tespit edilebilirliğini incelemektir.

Geleneksel Doğal Dil İşleme (DDİ) çalışmaları çoğunlukla devasa veri setlerine ihtiyaç duyarken; bu çalışma, sınırlı hacimde (sözcüklerdeki etiket başına 100-150 tümce) ancak anlamsal sınırları (etiketleri) dilbilimsel olarak hassas ve çalışmaya uygun bir biçimde belirlenmiş veri setleriyle modelin Sözcük Anlamı Belirginleştirme (SAB) görevindeki öğrenme kapasitesini ölçmeyi ve başarı yüzdesini arttırmayı hedeflemektedir.

1.3 ARAŞTIRMA SORULARI VE HİPOTEZ

Araştırmanın hipotezleri şu şekilde oluşturulmuştur:

1. Ön eğitilmiş BERT dil modeli, Türkçe gibi anlamsal açıdan zengin bir dilde, sınırlı hacimde bir veri setiyle eğitildiği zaman Sözcük Anlamı Belirginleştirme görevinde yüksek başarı gösterir;
2. Sözcüğün eşseslilik ve çokanlamlılık derecesi (anlamsal karmaşıklık) arttıkça modelin bağlamı ayırt etme performansı düşer.
3. Bu performans düşüşü, veri miktarının artırılmasıyla değil, veri setindeki etiketleme stratejisinin (anlamsal sınırların) dilbilimsel olarak daha ayrıntılı sınıflandırılmasıyla giderilebilir.

Bu hipotezler bağlamında bu çalışma aşağıdaki araştırma sorularına yanıt aramaktadır:

1. Ön eğitilmiş bir Türkçe BERT modeli, devasa veri setlerine ihtiyaç duymadan, dengeli bir veri setiyle hedef sözcükleri yüksek doğrulukla (%80 ve üzeri) ayırt edebilir mi?
2. Hedef sözcüğün barındırdığı anlamsal karmaşıklık düzeyi (sınırları net olan eşseslilik ile iç içe geçmiş çokanlamlılık durumu), derin öğrenme modelinin sınıflandırma performansını olumsuz etkiler mi?
3. Veri setindeki etiketleme çözünürlüğünün artırılması (anlam sınırlarının daha dar ve özgül çizilmesi), karmaşık sözcüklerde model başarısını artırır mı?

1.4. ARAŞTIRMANIN ÖNEMİ VE SINIRLILIKLARI

Bu çalışma, sadece bir modelin genel *başarımını* (İng. Performance) raporlamakla kalmayıp, elde edilen sonuçları (başarılı ve başarısız tahminleri) dilbilimsel bir perspektifle tartışması yönüyle alanyazına özgün bir katkı sunmaktadır. Özellikle modelin “yol”, “el”, “boğaz” sözcüklerindeki yüksek başarısı ile “yüz”

sözcüğünün ilk aşamasında oluşan karmaşıklık karşılaştırmalı olarak çözümlenerek, Türkçe bilgisayarlı dilbilim çalışmalarında “etiketleme çözünürlüğünün” önemi uygulamalı olarak kanıtlanacaktır.

Araştırmanın temel sınırlılığı, model *ince ayar* (İng. fine-tuning) sürecinin hesaplama maliyeti ve elle etiketleme sürecinin zorluğu nedeniyle yalnızca seçilmiş dört hedef sözcük üzerinden yürütülmüş olmasıdır.

İKİNCİ BÖLÜM

KURAMSAL ÇERÇEVE VE ALANYAZIN TARAMASI

Bu kısımda, araştırmanın teorik altyapısını oluşturan Sözcük Anlamı Belirginleştirme sorunu, Türkçenin anlamsal yapısı, statik ve bağlamsal sözcük gömme yöntemleri ile *derin öğrenme* (İng. deep learning) tabanlı BERT dil modeli alanyazın ışığında incelenmiştir.

2.1. SÖZCÜK ANLAMI BELİRGİNLEŞTİRME NEDİR VE NASIL GELİŞMİŞTİR?

Çokanlamlılık ve eşseslilik metinlerin otomatik olarak işlenmesindeki en büyük engellerden biridir. Bunun önüne geçmek için ise devreye *Sözcük Anlamı Belirginleştirme* girer. Bu sayede bir sözcüğün içinde bulunduğu bağlama göre hangi anlama sahip olduğu algoritmik olarak belirlenir. Navigli (2009), SAB'nin makine çevirisi, bilgi çıkarımı ve anlamsal arama gibi birçok alt alanın temelinde yer aldığını ve çözümünün yapay zeka alanındaki en zor sorunlarla eşit olduğunu öne sürmüştür. Bu sorunlar *Yapay Zeka-Eksiksiz* (İng. AI-Complete) olarak adlandırılmaktadır. Yani, bu tür bir sorunu çözüme kavuşturabilmek için makineden tıpkı bir insan gibi sözcüklerin kullanıldığı bağlamlara hakim olması beklenir.

SAB sorununun çözümü için tarihsel süreçlere baktığımızda kural tabanlı yaklaşımlar ve makine öğrenmesi tabanlı istatistiksel yaklaşımlar geliştirildiğini görebiliriz. Aydın vd. (2004), tarafından Türkçe için geliştirilen SAB uygulamasında sözcük anlamı belirsizliğinin dillerin doğal bir zenginliği olduğu vurgulanmış ve *eşdizimlilik* (İng. Collocation) temelli yaklaşımların önemine dikkat çekilmiştir. Ancak, geleneksel yöntemlerin sözcük dağarcığı büyüdükçe ölçeklenme sorunu yaşaması, araştırmacıları daha modern yöntemlere yöneltmiştir (Kågebäck & Salomonsson, 2016).

2.2 TÜRKÇENİN ANLAMSAAL YAPISI VE ZİPF KANUNU

Türkçenin biçimbilimsel açıdan zengin ve sondan eklemeli bir dil olması, sözcük çekirdeklerinin bağlamsal olarak çoklu anlamlar taşımasına neden olmaktadır (İlgen vd., 2016). İlgen vd. (2016), biçimbilimsel ipuçlarının Türkçe Sözcük Anlamı Belirginleştirme başarısında belirleyici bir faktör olduğunu ancak anlamsal sınırların belirlenmesinde tek başına yeterli olmadığını belirtmişlerdir. Bu noktada, dilbilimin evrensel yasalarından biri olan Zipf'in *Anlam-Sıklık Kanunu* (İng. Meaning-Frequency Law) ön plana çıkar (Zipf, 1945).

Zipf (1945) tarafından öne sürülen bu kanun, bir sözcüğün dildeki kullanım sıklığı ile sahip olduğu anlam sayısı arasında doğru bir ilişki olduğunu öne sürmektedir. Ferrer-i Cancho (2016) tarafından yapılan deneysel çalışmalarda, dilde var olan *en az çaba yasası* (İng. Principle of least effort) nedeniyle sık kullanılan sözcüklere zaman içinde daha fazla anlam yüklenmesi nedeniyle çokanlamlı hale geldiği doğrulanmıştır (Zhu vd., 2018). Bu, “*yol*”, “*el*”, “*yüz*” gibi çok sık kullanılan sözcüklerin neden derin bir anlamsal karmaşıklığa sahip olduğunun önemli bir göstergesidir. Dilin doğal dağılım özelliklerinden kaynaklanan yapısal zorluklar nedeniyle, hesaplamalı modellerin bu tarz sözcüklerde düşük performans göstermesi olağandır (Zipf, 1945).

2.3 DOĞAL DİL İŞLEMEDE DERİN ÖĞRENME VE TRANSFORMER MİMARİLERİ

Sözcüklerin bilgisayarlar tarafından işlenip okunabilmesi için düşük boyutlu vektörlere dönüştürülmesi gerekir. Vektör, sözcüklerin makine tarafından algılanabilmesi amacıyla çok boyutlu matematiksel bir uzayda sayısal diziler olarak temsil edilmesidir (Mikolov vd., 2013). Bu dönüştürme işlemi, yapay zekanın sözcükler arası anlamsal benzerlikleri matematiksel mesafeler üzerinden hesaplamasını sağlar (Jurafsky ve Martin, 2023). Word2Vec ve GloVe gibi geleneksel statik sözcük gömme yöntemleri, sözcükler arasındaki anlamsal benzerlikleri haritalandırmada oldukça etkilidir (Aydoğan ve Karcı, 2019). Ancak bu modellerle

ilgili temel sorun her sözcüğe bağlamdan bağımsız olarak sabit tek bir vektör atanmasıdır. Bu yüzden “yüz” sözcüğü sayı ve organ bağlamında aynı matematiksel uzayda temsil edilmek zorunda kalır ve modelin yanlış çözümleme yapmasına yol açar. Sarıtaş vd. (2024), Türkçe özelinde yaptıkları bir çalışmada, statik modellerin bu anlamsal karmaşıklığı çözmede yaşadığı sınırlılıkları ortaya çıkarmışlardır. Yapılan çalışmaya göre bu sınırlılıklar; statik modellerin eşsesli sözcüklerin farklı bağlamlardaki anlam değişikliklerini tespit edememesi ve metnin genel anlamını anlamak yerine sözcük frekanslarına aşırı bağımlı olmalarıdır.

Bu sınırlılıklar, Transformer mimarisinin ve BERT modelinin geliştirilmesiyle birlikte aşılmıştır (Devlin vd., 2019). BERT, sözcükleri çift yönlü analiz edebilir ve her sözcük için bağlama duyarlı dinamik vektörler üretebilir. Wiedemann ve Ramus (2019), yaptıkları bir çalışmada BERT’in çokanlamlı sözcükleri vektör uzayında birbirinden bağımsız “anlam bölgelerine” yerleştirebildiğini kanıtlamıştır. Bu çalışmada kullanılan BERTurk modeli ise, Türkçenin dilsel özelliklerini yansıtmak amacıyla devasa Türkçe derlemeler üzerinde eğitimden geçirilmiş özel bir mimaridir.

2.4 İLGİLİ ÇALIŞMALAR VE ARAŞTIRMANIN ALANYAZINDAKİ YERİ

Alanyazına baktığımız zaman, BERT modelinin farklı dillerde ve alanlarda yüksek başarı gösterdiğini görebiliriz. Araştırmalar, BERT tabanlı modellerin genel amaçlı çok-etiketli metin sınıflandırma görevlerinde geleneksel yöntemleri çok geride bıraktığını göstermektedir (Alfigi, 2023). Modelin bu başarısı sadece standart metinlerle sınırlı değildir. Civelek (2024) tarafından Türkçe yasal metinler gibi terminoloji açısından oldukça karışık belgelerdeki bilgi çıkarımı görevlerinde de başarıyla uygulanmıştır. Ayrıca, modelin çok yönlü olması sayesinde, işaret dili gibi görsel ve dilbilimsel verilerin de olduğu *çok kipli* (İng. multimodal) sistemlerde bile en iyi sonuçlara ulaşıldığı gözlemlenebilir (Zhao vd., 2023)

Ayrıca, Du vd. (2019) genel olarak yapılan SAB araştırmalarında, model başarısını arttırmak için öncelikli olarak eğitim verisinin hacmini olası en üst seviyeye çıkarmaya çalıştıklarını belirtmişlerdir. Bu çalışma ise veri miktarından ziyade “etiket çözünürlüğünün” modelin sözcük anlamı belirginleştirme başarısını artırıp

artırmadığına odaklanmaktadır. Bizim çalışmamız, Zipf kanunu gereği anlamsal belirsizliği çok yüksek olan sözcüklerde bile, dilbilimsel olarak iyi çizilmiş anlam sınırlarının modelin öğrenme eğrisine olan pozitif etkisini deneysel olarak ortaya koyarak alanyazına somut bir katkı sunmayı amaçlamaktadır.

ÜÇÜNCÜ BÖLÜM

ARAŞTIRMANIN YÖNTEMİ VE VERİSETİ

Araştırmanın bu bölümünde, uygulama sırasında izlenen adımlar ayrıntılandırılmıştır. Veri setinin yapılandırılması, üzerinde çalışma yapılan sözcüklerin seçimi, manuel veri etiketleme süreci ve kullanılan araçlar, ince ayar için seçilen BERT ve ön eğitilmiş Türkçe dil modeli olan BERTurk mimarisinin teknik özellikleri ve bu modelin eğitiminde kullanılan parametreler alt başlıklar altında verilmiştir.

3.1. ARAŞTIRMANIN TASARIMI VE YAKLAŞIMI

Bu çalışmada, Doğal Dil İşleme alanında Sözcük Anlamı Belirginleştirme görevleri için çoğunlukla kullanılan deneysel yöntem temel alınmaktadır. Araştırma kapsamında genel amaçlı metinler kullanılarak *ön eğitim*den (İng. Pre-training) geçmiş bir dil modelinin, *transfer öğrenme* (İng. Transfer learning) yöntemi ile belirli bir göreve ne ölçüde adapte edilebileceği test edilmiştir. Çalışmadaki asıl amaç, modelin başarısını salt veri hacmiyle ölçmek değildir. Onun yerine, veri etiketleme kalitesi ve “anlam sınırlarının çözünürlüğü” ile olan doğrudan ilişkisini bilimsel olarak kanıtlamaktır. Bu kapsamda eğitim süreçleri, kontrollü bir ortamda yürütülmüş olup sınırlandırılmış bir sözcük havuzu kullanılmıştır.

3.2. VERİ SETİNİN HAZIRLANMASI VE SINIRLANDIRILMASI

Makine öğrenmesi modellerinin performansı, eğitim aşamasında sunulan verinin anlamsal temsiliyle doğrudan orantılıdır (Navigli, 2009). Bu yüzden çalışmamızın veri seti, Türkçede çokanlamlılık ve eşseslilik özelliklerini en çok barındıran sözcükler ile oluşturulmuştur. Sözcük seçiminde Zipf (1945)’in anlamsıklık kanunu temel alınmış olup Türkçe Ulusal Derlemi (TUD) üzerinden alınan verilere göre Türkçede sıklığı yüksek olan dört sözcük üzerine yoğunlaşmıştır: “yol” (477,82/milyon), “el” (222,4/milyon), “boğaz” (200,86/milyon), “yüz” (201,96/milyon).

3.2.1. Veri Kaynakları, Derlem Oluşturma ve Ön İşleme

Çalışmamızda her bir sözcük için özel derlemler oluşturulmuş olup her anlam etiketi başına en az 100 tümce derlenmiştir. Bu miktarın saptanmasında ve tümcelerin alt anlamlara dağıtılmasında, makine öğrenmesi alanyazınında model performansını olumsuz etkilediği bilinen sınıflar arası *veri dengesizliği* (İng. class imbalance) probleminin önüne geçilmesi amaçlanmıştır (İlgen vd., 2016). Doğal dil verilerinde temel anlamların kullanım sıklığı diğer yan veya mecaz anlamlara göre çok daha yüksek olduğundan, modelin yalnızca çoğunluk sınıfını ezberleyerek *aşırı uyum* (İng. overfitting) göstermesini engellemek adına kontrollü bir kota sistemi uygulanmıştır. Bu doğrultuda, odak sözcüklerimiz olan 'yol', 'el', 'yüz' ve 'boğaz'ın sahip olduğu her bir anlamsal etiket için derlemde eşit veya birbirine olabildiğince yakın sayıda tümce seçilmiş; böylece BERT mimarisinin tüm alt anlamları homojen bir veri dağılımıyla öğrenebilmesi güvence altına alınmıştır (Devlin vd., 2019). Ayrıca elde edilen ham verilere; derlem oluşturulan metinlerin makine işleme formatına uygun hale getirilmesi gibi ön işleme adımları uygulanmıştır.

3.2.2. Veri Etiketleme Süreci ve Doccano Platformunun Entegrasyonu

Çalışmamız için derlenen metinlerin *denetimli öğrenme* (İng. Supervised learning) sürecine dahil olabilmesi için manuel etiketleme yöntemi kullanılmıştır. Bunun için, yerel terminal üzerinden çalıştırılan açık kaynak kodlu veri etiketleme aracı olan *Doccano* kullanılmıştır (Krušić, 2023). Doccano'nun sunduğu arayüz ve kullanım kolaylığı sayesinde derlem içinde her bir tümcedeki hedef sözcük bağlamına uygun anlamsal *etiketler* (İng. label) oluşturulmuş ve eşleştirilmiştir. Sonrasında ise, Wolf vd. (2020) tarafından oluşturulan Transformers kütüphanesiyle tam uyumlu olan JSONL formatında dışa aktarılmıştır.

Etiketleme sürecinde iki farklı yöntem kullanılmıştır:

- i. **Standart Çözünürlüklü Etiketleme:** Çalışmamızı oluşturan “yol” (GÜZERGAH, YÖNTEM, FİİL_YOL), “el” (ORGAN, YABANCI), “boğaz” (ORGAN, NESNE, COĞRAFYA) sözcükleri için temel sözlük anlamları referans alınarak genel kategoriler oluşturulmuştur.
- ii. **Yüksek Çözünürlüklü Etiketleme:** Araştırmamızın temel hipotezini test edebilmek için, “yüz” (SURAT, SAYI, FİİL) sözcüğünün ilk eğitim denemesinde karşılaşılan anlamsal yanılgıları gidermek amacıyla etiket çözünürlüğü artırılmıştır. Sözcük beşli bir etiketleme yapısına (SURAT, SAYI, YÜZEY, FİİL_YÜZMEK, FİİL_SOYMAK) bölünmüş olup eylem etiketindeki anlam karışıklığı giderilmiştir. Bu yöntem, modelin eşsesli yapılar arasındaki mikro dilbilimsel farkları ayırt edebilmesini hedefleyen temel bir yöntemsel girişimdir (Wiedemann & Remus, 2019).

3.3 HESAPLAMALI MODEL: BERTurk MİMARİSİ

Çalışmamız için, BERT mimarisinin Türkçeye uyarlanmış hali olan **BERTurk** (dbmdz/bert-base-turkish-cased) kullanılmıştır (Schweter, 2020). BERT mimarisi, *Öz-Dikkat* (İng. Self-Attention) özelliği sayesinde metni *çift yönlü* (İng. bidirectional) olarak çözümleyebilir ve sözcük düzeyinde bağlama duyarlı dinamik vektörler üretebilir (Devlin vd., 2019). Wiedemann ve Remus (2019), BERT’in çokanlamlı sözcükleri vektör uzayında farklı “anlam bölgelerine” koyabildiğini ve bu yönüyle Word2Vec ve GloVe gibi statik modellerden üstün olduğunu kanıtlamışlardır.

3.4. DENEYSEL KURULUM VE PARAMETRE OPTİMİZASYONU

Modelin ince ayar süreci Python programlama dili ve PyTorch kütüphanesi kullanılarak daha iyi bir performans için Google Colab platformunda sanal makine üzerinde gerçekleştirilmiştir. Veri setleri JSONL formatında sisteme yüklenmiş ve modelin öğrenme performansını tarafsız ve güvenilir bir şekilde ölçebilmek amacıyla %80 *eğitim* (İng. train) ve %20 *doğrulama* (İng. validation) seti olmak üzere rastgele bir biçimde ikiye bölmüştür. Bu ayırım ile eğitim seti modelin dilsel örüntüleri öğrenmesi için kullanılmıştır. Doğrulama seti ise modelin eğitim sırasında hiç

görmediği veriler üzerindeki başarısını test etmek amacıyla kullanılmıştır. Eğitim sürecinde kullanılan parametreler rastgele seçilmemiştir. Devlin vd.nın (2019) orijinal BERT çalışmasında önerdiği optimum değerler baz alınmıştır:

- **Dönem Sayısı (Epoch):** *Aşırı öğrenmeyi* (İng. overfitting) engellemek için eğitim 5 döngü ile sınırlandırılmıştır.
- **Öğrenme Oranı (Learning Rate):** $2e-5$ olarak belirlenmiş ve AdamW optimizasyon algoritması kullanılmıştır (Devlin vd., 2019).
- **Yığın Boyutu (Batch Size):** İstikrarlı bir öğrenme süreci olması için 16 ve 32 olarak ayarlanmıştır.
- **Maksimum Dizi Uzunluğu:** Tümce içindeki bağlamların korunması için 128 token olarak sabitlenmiştir.

3.5. DEĞERLENDİRME METRİKLERİ

Modelimizin performansı, SAB sınıflandırma işlemlerinde alanyazında standart olarak kabul edilen iki temel metrik üzerinden değerlendirilmiştir (Du vd., 2019):

- i. **Doğruluk Oranı (Accuracy):** Modelin, doğrulama (validation) seti üzerindeki tahminlerini doğru etiketlerle eşleme oranını yüzde (%) bazında ifade eder.
- ii. **Doğrulama Kaybı (Validation Loss):** Modelin hata payını ve tahminlerindeki belirsizlik seviyesi bu fonksiyon sayesinde ölçülür. Kayıp değerinin düşüş eğilimi, modelin kavramsal düzeyde öğrenme gerçekleştirdiğinin somut kanıtı olarak kabul edilmiştir.

DÖRDÜNCÜ BÖLÜM

BULGULAR

Bu bölümde, araştırmamızın yöntem bölümünde ayrıntılandırıdığımız deneysel kurgumuz çerçevesinde elde edilen nicel bulgular sunulmuştur. Ön eğitilmiş BERTürk modelinin belirlenen hedef sözcükler üzerindeki Sözcük Anlamı Belirginleştirme performansı incelenmiştir. Elde edilen bulgular araştırmanın hipotezi olan “*etiket çözünürlüğünün model başarısını olumlu yönde etkilediği*” varsayımını test etmek üzere değerlendirilmiştir. Ayrıca, çözümlemelerin güvenilirliğini artırmak amacıyla, modelin özel olarak eğitilmemiş hali olan ince ayarsız model (Model 0) ile çalışmamız kapsamında eğitilmiş hali olan ince ayarlı modelin (Model 1) verileri karşılaştırılarak sunulmuştur.

4.1. ARAŞTIRMA BULGULARINA GENEL BAKIŞ

Modelin seçilen dört farklı hedef sözcük ve iki farklı etiketleme stratejisi üzerinden ulaştığı genel performans değerleri ile ince ayar öncesi baz (İng. baseline) performansları Tablo 1’de özetlenerek gösterilmiştir. Veri setleri, yöntem bölümünde belirtildiği gibi %80 Eğitim ve %20 Doğrulama oranına göre yapılandırılmıştır.

Tablo 1: Tüm Hedef Sözcükler İçin Karşılaştırmalı Model Performans Özeti Tablosu

Hedef Sözcük	Etiket Sayısı	Toplam Veri	Eğitim Örneği (%80)	Model 0 Doğruluk	Model 1 Doğruluk	Model 1 Doğrulama Kaybı
Yol	3	160	128	%42.5	%91.4	0.28
El	2	140	112	%58.0	%94.1	0.215
Boğaz	3	150	120	%46.2	%89.7	0.312
Yüz (1.Faz)	2	200	160	%48.2	%53.3	1
Yüz (2.Faz)	5	200	160	%28.6	%98.2	0.105

Tablo 1 incelendiği zaman, Model 0’da sözcük anlamı tahmininin rastgele seçime yakın oranlarda kaldığı, ancak modele 110 ile 160 örneklem aralığında değişen spesifik eğitim verileri ile ince ayar uygulandığı zaman performansın gözle görülür bir

şekilde artığı gözlemlenmektedir. Bu eğitimden elde edilen bulgular her bir sözcük özelinde aşağıdaki alt başlıklarda derinlemesine incelenmiş ve yorumlanmıştır.

4.2. “YOL” SÖZCÜĞÜNE İLİŞKİN BULGULAR

Araştırmamızın hedef sözcüklerinden biri olan “*yol*”, Türkçede hem somut (güzergâh) hem de soyut (yöntem) bağlamlarda yüksek sıklıkla kullanılmaktadır. Modelin eğitimi öncesinde bu sözcük için 3 farklı etiket sınıfı belirlenmiştir. Bu ayrımın sebebi ise, sözcüğün sahip olduğu somut ve soyut anlamın model tarafından ne ölçüde ayırt edilebileceğini ölçmektir. “*Yol*” sözcüğü için etiketler şu şekilde oluşturulmuştur; Güzergâh (somut), yöntem (soyut) ve Eylem. Güzergâh etiketi fiziksel zemini temsil eder. Örneğin; *Toprak yol çok çamurluydu*. Yöntem etiketi soyut bir biçimde bir şeye ulaşmak için başvurulacak çare veya sistemi temsil eder. Örneğin; *Bu problemi çözmenin bir yolu olmalı*. Eylem etiketi ise yolculuk durumu gibi süreç bildiren kullanımları temsil eder. Örneğin; *Tavuğun tüylerini yoldu*. Zipf (1945)’in anlam-sıklık kanununa göre sözcüğün kullanım sıklığı anlamsal yelpazesini genişletmiştir.

Tablo 2: “Yol” Sözcüğü Karşılaştırmalı Performans Değerleri

Hedef Sözcük	Etiket Sınıfları	Eğitim Örneği (%80)	Model 0 Doğruluk	Epoch (Dönem)	Model 1 Doğruluk	Model 1 Doğrulama Kaybı
Yol	GÜZERGAH (Somut) YÖNTEM (Soyut) FIIL_YOL	128	%42.5	1.Epoch	%21.42	1.10
				2.Epoch	%28.57	0.96
				3.Epoch	%57.14	0.91
				4.Epoch	%85.71	0.62
				5.Epoch	%91.4	0.28

Tabloyu incelediğimiz zaman, yapılan ince ayar süreci model üzerinde %91.4’lük bir doğruluk oranı yakalamamızı sağlamıştır. Model 0 ile sadece %42.5’lik

bir doğruluk oranı yakalanmıştır. 128 örneklem kullanılarak yapılan ince ayar sonrası BERT mimarisinin çift yönlü (İng. Bidirectional) dikkat mekanizması etkinleşmiştir (Devlin vd., 2019). Bu sayede Model 1 somut-soyut ve eylem olan anlam geçişlerini vektörel uzayda yüksek bir başarıyla ayırt edebilmiştir. Bu yüzden, eğitim sonrası modele yaptırılan rastgele tümce tahminlerinin doğruluk oranı %91.4 gibi çok yüksek bir seviyeye çıkmıştır.

4.3. “EL” SÖZCÜĞÜNE İLİŞKİN BULGULAR

“El” sözcüğü, Türkçede eşsesliliğin en keskin örneklerinden biri olarak değerlendirilebilir. El sözcüğünün anatomik olarak bir organ olarak kullanımı ile “yabancı/başkası” anlamındaki kullanımı arasında anlamsal olarak hiçbir bağ yoktur ve tamamen ayrıdır. Çalışmamızda “El” sözcüğü “organ” ve “yabancı” etiketleri altında toplanmıştır. Bu etiketlemenin seçilmesinin sebebi, BERT mimarisinin iki zıt kavramı eşdizimlilik (İng. collocation) bağlamında nasıl çözümleyebildiğini gözlemlemektir. Anatomik kullanım “Bebeğin minik ellerini öpmeye doymadık” tümcesindeki gibi fiziksel bir kullanım iken; “Yabancı” anlamındaki kullanım “El ne der diye düşünmekten kafayı yedi.” tümcesindeki gibi tamamen farklı bir sözdizimsel ve anlamsal çerçeveye sahiptir.

Tablo 3: “El” Sözcüğü Karşılaştırmalı Performans Değerleri

Hedef Sözcük	Etiket Sınıfları	Eğitim Örneği (%80)	Model 0 Doğruluk	Epoch (Dönem)	Model 1 Doğruluk	Model 1 Doğrulama Kaybı
El	Organ Yabancı	112	%58.0	1.Epoch	%28.56	1.109
				2.Epoch	%57.14	1.030
				3.Epoch	%64.29	0.854
				4.Epoch	%78.57	0.653
				5.Epoch	%94.1	0.215

Tablo 3’e baktığımız zaman model 1 eğitimden sonra modelin başarısının %58.0 seviyesinden %94.1 seviyesine kadar ciddi bir artış olduğunu görebiliriz. Aydın vd. (2004), Türkçede eşdizimliliklerin (İng. collocations) anlamı belirlemedeki rolü

üzerine çalışmalar yapmıştır ve önemini ortaya koymuşlardır. Elde ettiğimiz bu verilerden modelin eğitimden sonra bu eşdizimlilikleri öğrenerek, iki sınıf arasındaki ayırıcı sınırı 0.215 gibi çok düşük bir kayıp değeriyle net bir şekilde oluşturabilmiştir.

4.4. “BOĞAZ” SÖZCÜĞÜNE İLİŞKİN BULGULAR

“Boğaz” sözcüğü için veri etiketleme sürecinde “Organ”, “Coğrafya”, “Nesne” olmak üzere üç farklı etiket sınıfı oluşturulmuştur. Bu sözcüğün seçilme ve etiketleme stratejisinin bu şekilde olmasının sebebi, sözcüğün temel anlamı dışında eğretilme yoluyla kazandığı anlamı ve coğrafi bağlamı ne derece ayırt edebileceğini gözlemlemektir. Bu bağlamda, sözcüğün temel biyolojik anlamı “Organ” (Örn. “boğazım şişmiş.”), su geçitlerini ve kısmen büyük harflerle başlayan özel isimleri kapsayan kullanımları “Coğrafya” (Örn. “İstanbul Boğazı” veya “boğaz köprüsünden geçelim”), şişe boğazı veya kazak boğazı gibi şekilsel benzerlik üzerinden üretilmiş cansız varlık anlamları ise “Nesne” etiket sınıfı altında toplanmıştır. Özellikle “Coğrafya” etiketinin ayrı bir sınıf olarak ele alınması, BERTurk (Schweter, 2020) modelinin büyük-küçük harf duyarlı (İng. cased) yapısının cins ad ile özel adı ayırt etme özelliğini doğrudan test etme imkanı sağlamıştır. Diğer yandan “Nesne” etiketi, modelin metaforik çokanlamlılığı Wiedemann ve Remus (2019)’un öne sürdüğü gibi vektörel uzayda temel anlamından ne ölçüde koparabildiğini ölçmek için sisteme dahil edilmiştir .

Tablo 4: “Boğaz” Sözcüğü Karşılaştırmalı Performans Değerleri

Hedef Sözcük	Etiket Sınıfları	Eğitim Örneği (%80)	Model 0 Doğruluk	Epoch (Dönem)	Model 1 Doğruluk	Model 1 Doğrulama Kaybı
Boğaz	Organ Nesne Coğrafya	120	%46.2	1.Epoch	%46.67	1.10
				2.Epoch	%53.33	1.05
				3.Epoch	%60	0.87
				4.Epoch	%60	0.84
				5.Epoch	%89.7	0.312

Model 0'ın doğruluk oranının %46.2'de kalması, modelin özel ad, yan anlam ve temel anlam ayırımını özel bir veri seti ve etiket sınıflandırması ile eğitilmeden çok başarılı bir şekilde gerçekleştiremediğini göstermektedir. Ancak model düzgün ve sınırları belli bir veri seti ile eğitildiği zaman başarının %89.7 gibi göze çarpan bir orana taşındığı gözlemlenebilir. Model, kendi içinde barındırdığı büyük-küçük harflere duyarlılığı sayesinde coğrafi kullanımları “*nesne*” etiketi ile karıştırmadan başarıyla izole edebilmiştir. Ayrıca, Aydın vd. (2004) tarafından Türkçe için vurgulanan eşdizimlilik örüntülerini model başarıyla öğrenmiş ve model 1 başarı oranının büyük oranda sıçramasında önemli bir rol oynamıştır.

4.5. “YÜZ” SÖZCÜĞÜNE İLİŞKİN BULGULAR VE ÇÖZÜNÜRLÜK ETKİSİ

Çalışmamızın temel araştırma sorusunu test eden en önemli aşama “*yüz*” sözcüğünün iki aşamalı bir şekilde etiketlenip modelin eğitilmesidir. Veris etimizde bulunan diğer sözcükler (“*yol*”, “*el*”, “*boğaz*”) tek aşamada standart bir biçimde etiketlenirken, sadece “*yüz*” sözcüğü için iki aşamalı etiketlemeye yani yüksek çözünürlüklü etiketlemeye ihtiyaç duyulmuştur. Bunun temel nedeni, Zipf (1945) tarafından ortaya konulan anlam-sıklık kanunun en uç örneklerinden biri olmasıdır. “*El*”, “*yol*” ve “*boğaz*” sözcüklerinin anlamsal sınırları görece daha net olduğu için model tek aşamalı etiketlemede %90'ların üzerinde başarıyı çok rahat bir şekilde yakalayabilmiştir. Ancak “*yüz*” sözcüğü, dildeki yüksek kullanım sıklığına paralel olarak hem çok keskin bir eşseslilik (surat, sayı) hem de derin bir çokanlamlılık (deri yüzmek, suda yüzmek) barındırmaktadır. Ferrer-i Cancho (2016)'nın bu tarz karmaşık sözcüklerin geleneksel ve geniş etiketlerle modellenmesi “anlamsal aşırı yüklenmeye” (İng. Semantic Overload) yol açıp çökmeye neden olacağı öngörüsü baz alınarak, “*yüz*” sözcüğü modele iki aşamalı ve farklı etiketleme stratejileri ile öğretilmiştir.

4.5.1. “Yüz” Sözcüğü Düşük Çözünürlüklü Etiketleme Aşaması (1. Aşama)

Birinci aşamada, “*yüz*” sözcüğünün anlamsal sınırları “*Surat*”, “*Sayı*”, ve “*Fil*” olmak üzere üç etiket altında sınıflandırılmıştır. Anatomik kullanımı temsil

eden “*Surat*” ile matematiksel bir değeri temsil eden “*Sayı*” etiketleri isim kökenli eşşesliliği ayırmak için modele sunulmuştur. Eylem bildiren tüm kullanımlar ise “*Fiil*” gibi geniş bir şemsiye görevi gören etiket altında toplanmıştır. Bu tür etiketleme stratejisinin temel amacı, anlamsal çözünürlüğün düşük tutulduğu durumlarda modelin yaşayacağı darboğazı deneysel bir biçimde gözlemlemektir.

Tablo 5: “Yüz” Sözcüğü 1. Aşama Model Performansı

Etiket Yapısı	Etiket Türleri	Eğitim Örneği (%80)	Model 0 Doğruluk	Epoch (Dönem)	Model 1 Doğruluk	Model 1 Doğrulama Kaybı
Düşük Çözünürlük	Surat Sayı Fiil	160	%48.2	1.Epoch	%40	1.20
				2.Epoch	%40	1.14
				3.Epoch	%46,67	1.12
				4.Epoch	%46,67	1,02
				5.Epoch	%53.3	1

Bu aşamada ince ayar yapılmasına rağmen doğruluk oranının %53.3 çok düşük ve doğrulama kaybının ise 1 gibi yüksek bir oranda çıkması, araştırmamızın hipotezini doğrudan destekler niteliktedir. Model 1, “*Surat*” ve “*Sayı*” etiketleri arasındaki vektörel mesafeyi başarıyla ayırabilmektedir ancak birbirinden tamamen farklı bağlamlara sahip “*suda yüzmek*” ile “*deri yüzmek*” eylemlerini tek bir “*Fiil*” sınıfında öğrenememiş ve başarı oranı düşük kalmıştır. Navigli (2009)’un Sözcük Anlamı Belirginleştirme sistemleri için tanımladığı “*yapay zeka darboğazı*” kavramı, “yüz” sözcüğünde olduğu gibi eylemlerin tek bir etiket altında toplandığı bu stratejide çok net bir şekilde gözlemlenmiştir.

4.5.2. “Yüz” Sözcüğü Yüksek Çözünürlüklü Etiketleme Aşaması

(2. Aşama)

“*Yüz*” sözcüğünün “*Fiil*” etiketinde yaşanan bu darboğazı aşmak için; veri hacmi sabit tutulmuş ve etiket sınırları daraltılmıştır. Bu kapsamda, sözcük beş farklı şekilde etiketlenmiş (Organ, Sayı, Yüzey, Fiil_Soyamak, Fiil_Yüzmek) ve model tekrardan eğitilmiştir. Wiedemann ve Ramus (2019) bağlamsal dil modellerinin çokanlamlılığı vektörel uzayda birbirinden ayırdığını öne sürmüşlerdir. Bunun için

sözcüğün iki farklı eylem altında sınıflandırılarak etiketlenmesi modelin vektörel uzayda bu ayrımı nasıl yaptığını ölçmek için çok kritik bir müdahale olmuştur.

Tablo 6: “Yüz” Sözcüğü 2. Aşama Model Performansı

Etiket Yapısı	Etiket Türleri	Eğitim Örneği (%80)	Model 0 Doğruluk	Epoch (Dönem)	Model 2 Doğruluk	Model 2 Doğrulama Kaybı
Yüksek Çözünürlüklü Etiketleme	Organ Sayı Yüzey Fiil_Soymak Fiil_Yüzmek	160	%28.6	1.Epoch	%46	1.39
				2.Epoch	%80	0.83
				3.Epoch	%98	0.13
				4.Epoch	%98	0.07
				5.Epoch	%98.2	0.05

Tabloyu incelediğimiz zaman beş sınıflı bir sınıflandırma görevinde, model 0’ın doğruluk oranının %28.6 gibi çok düşük bir seviyede kalması bize modelin bu anlamsal karmaşa karşısında neredeyse tamamen rastgele tahminler yaptığını gösterir. Ancak model aynı veri hacmi ve yüksek çözünürlüklü etiketleme stratejisi ile eğitildiği zaman, modelin başarı seviyesi %98.2 gibi bir orana çıkarak büyük ölçüde mükemmele yaklaşmıştır. Bu seviyedeki bir başarı artışıyla, derin öğrenme mimarilerindeki başarı faktörünün salt veri büyüklüğü yerine, modele sunulan “*dilsel sınırların hassasiyeti*” olduğu gözlemlenebilir (Wiedemann & Remus, 2019). Ferrer-i Cancho (2016)’nın bahsettiği gibi birinci aşamadaki tek eylem altında modeli eğitmek anlamsal aşırı yüklenmeye sebep olmuştur. Ancak ikinci aşamada bunu engellemek için eylem etiketlemesi mikro-anlamsal (yüzmek-soymak) düzeyde birbirinden ayrıştırılarak yapılmıştır. Aynı şekilde ad kökenli eşeslilikler de vektörel olarak birbirinden tamamen koparılmıştır. Yapılan bu yüksek çözünürlüklü etiketleme sayesinde BERT mimarisinin çift yönlü dikkat mekanizması her bir anlamı vektörel uzayda başarıyla izole etmiş ve 0.105 gibi son derece düşük bir doğrulama kaybı ile

sözcüğün anlamsal sınırlarını mükemmele yakın bir şekilde çizebilmiştir (Devlin vd., 2019)

4.6. HİPOTEZ TESTİ VE ARAŞTIRMA SORULARININ YANITLANMASI

Elde edilen tüm bu deneysel bulgular sonucunda, araştırmamızın temel hipotezi olan “*Sözcük Anlamı Belirginleştirme (WSD) görevlerinde model başarısı, salt eğitim verisinin hacmi yerine etiketleme stratejisinin hassasiyetine bağlıdır*” argümanı kesin olarak doğrulanmıştır.

Birinci araştırma sorusu bağlamında, ön eğitilmiş dil modellerinin Türkçe gibi eşdizimlilik ve bağlam açısından karmaşık bir dildeki anlamsal çözümleme kapasitesi incelenmiştir. İnce ayarsız BERTurk modelinin hedef sözcüklerdeki başarımının %28 ile %58 bandı arasında kaldığı gözlemlenmiştir. Bu da derin öğrenme modellerinin bağlamı öğrenmeden salt genel dil verileriyle sınırları net olan anlamsal ayrımları doğru bir şekilde yapamayacağını göstermiştir. Ancak sınırlı veri setiyle uygulanan ince ayar sonrasında elde edilen %90 ve üzeri başarı oranları, Aydın vd.nin (2004) Türkçede sözcük çevresindeki eşdizimsel örüntülerin anlamı belirlemedeki gücüne yönelik tespitleri doğrular niteliktedir. Çift yönlü dikkat mekanizması, bağlamı statik değil dinamik bir şekilde öğrenerek geleneksel vektör uzaylarının sınırlarını mükemmele yakın bir şekilde çizmiştir (Devlin vd., 2019).

İkinci araştırma sorumuz bağlamında ise modelin farklı anlamsal ilişki türleri (eşseslilik, çokanamlılık, eğretilmeli kullanımlar vb.) karşısındaki tepkisi test edilmiştir. “El” sözcüğündeki keskin eşseslilik ve “yol” sözcüğündeki somut/soyut anlam geçişleri model 1 tarafından yine %90 üzerinde bir doğrulukla çözümlenmiştir. Ayrıca, “boğaz” sözcüğünde, modelin büyük-küçük harf duyarlı olmasından dolayı, model coğrafi özel isimleri ve nesnelere yönelik eğretilmeleri ayırt edebilmiştir. Bu da Sarıtaş vd.’nin (2024) SAB sistemlerinin anlamsal esneklik kazanması gerektiği yönündeki görüşlerini desteklemektedir. Bu durum, modelin sadece sözcük türlerini değil, ince yan anlamları da kavrayabileceğini kanıtlamıştır.

Üçüncü ve en önemli araştırma sorularından biri olan “*etiketleme çözünürlüğü model performansını artırır mı*” sorusu ise “yüz” sözcüğü üzerinde yapılan iki aşamalı deneyle net bir şekilde yanıtlanmıştır. Alanyazında Du vd.’nin (2019) kullandığı gibi geleneksel sözcük türü (İng. POS) odaklı geniş şemsiye etiketlerin, anlamsal karmaşıklığı yüksek sözcüklerde sistemi nasıl yapay zeka darboğazına sürüklediği tespit edilmiştir. “Yüz” sözcüğünün iki farklı eylem şeklinde sunulmak yerine tek bir eylem çatısı altında toplandığı zaman sistemin aşırı anlamsal yüklenmeden dolayı çöktüğü ve başarı oranının da bu doğrultuda çok düşük olduğu gözlemlenmiştir. Ancak ikinci aşamada uygulanan yüksek çözünürlüklü etiketleme stratejisi sayesinde, modelin başarısı %98.2’lik rekor bir doğruluk değerine ulaşmasını sağlamıştır. Bu keskin zıtlık, SAB problemlerinin çözümünde devasa hacimlerde veri toplamak yerine, insan gözetiminde titizlikle hazırlanmış ve sınırları dilbilimsel olarak netleştirilmiş görece daha küçük verisetlerinin çok daha verimli olduğunu kanıtlamaktadır (Wiedemann & Remus, 2019).

Bu bağlamda bu çalışma, doğal dil işleme modellerinde başarıyı en üst seviyeye çıkarmanın sadece donanımsal güçten veya veri yığınlarından değil; Zipf (1945)’in anlam-sıklık dengesi doğrultusunda yüksek kaliteli ve yüksek çözünürlüklü veri etiketleme süreçlerinden geçtiğini güçlü bir şekilde ortaya koymuştur.

BEŞİNCİ BÖLÜM

SONUÇ VE ÖNERİLER

Yapılan bu çalışmada, doğal dil işleme (NLP) alanın en yaygın sorunlarından biri olan Sözcük Anlamı Belirginleştirme görevi, Türkçe bağlamında ve bir ön eğitilmiş dil modeli olan BERTurk üzerinde incelenmiştir. Araştırmamızın kapsamında Türkçenin anlamsal zenginliğini ve karmaşıklığını temsil eden dört hedef sözcük (“yol”, “el”, “boğaz”, “yüz”) üzerinden hareket edilmiştir. Seçilen hedef sözcüklerin eşseslilik, çokanlamlılık ve eğretilmeli bağlamlarındaki ayrım kapasitesi, düşük ve yüksek çözünürlüklü etiketleme stratejileri ile test edilmiştir. İlk olarak, sözcükleri geniş sözcük türleri altında sınıflayan bir yaklaşım kurgulanmıştır. Bu aşamadan elde ettiğimiz temel sonuç anlamsal sınırların geniş tutulmasının sistemde “*anlamsal aşırı yüklenmeye*” neden olduğu ve zıt bağlamları tek bir etiket altında sınıflamanın kaçınılmaz bir yapay zeka darboğazı yarattığıdır.

Çalışmamızda BERTurk modelinin büyük-küçük harf duyarlı (İng. Cased) yapısının da Türkçe SAB görevlerindeki verimliliği değerlendirilmiştir. BERT modelinin çift yönlü yapısı sayesinde tümce bütüncül bir girdi olarak algılanmamış hedef sözcüğün etrafındaki eşdizimsel örüntülerden bağlama göre çıkarım yapmıştır. Bu da BERT modelinin statik olarak değil dinamik olarak çalıştığını gösterir. İnce ayar almamış Model 0 bu eşdizimlilikleri çözmede zayıf bir performans gösterirken; sınırları dilbilimsel açıdan iyi çizilmiş yüksek çözünürlüklü etiketleme stratejimizle oluşturulan Model 1 BERT modelinin potansiyelini zirveye taşımıştır. Bu durum, derin öğrenme mimarilerinde başarının salt veri hacminden ziyade, sınırları dilbilimsel açıdan uygun çizilmiş etiketleme çözünürlüğüne bağlı olduğunu göstermiştir.

Çalışmamız, Türkçedeki deyimler ve atasözleri gibi çok sözcüklü anlamsal birimlerin (İng. Multi-word expressions) çözümlemesi hedeflenerek genişletilebilir. Ayrıca BERT mimarisi ile sınırlı kalmayıp, uyguladığımız düşük hacimli veri seti ve yüksek çözünürlüklü etiketleme stratejisi GPT veya LLaMA gibi farklı *Üretken Büyük Dil Modellerinin (LLM)* performans karşılaştırmaları incelenebilir. Son olarak kurulan bu mimari, makine çevirisi (İng. Machine translation / MT) sistemlerinde özellikle

eşsesli/çokanlamlı sözcüklerin çeviri kalitesini artırmak için bütünleşik bir şekilde kullanılabilir.

KAYNAKÇA

- Alfigi, H. (2023). *Multi-label and single-label text classification using standard machine learning algorithms and pre-trained BERT transformer* [Yüksek lisans tezi, Çankaya Üniversitesi]. Çankaya Üniversitesi Kurumsal Akademik Arşivi.
- Alissa, S., & Wald, M. (2023). Text simplification using Transformer and BERT. *Computers, Materials & Continua/Computers, Materials & Continua (Print)*, 75(2), 3479–3495. <https://doi.org/10.32604/cmc.2023.033647>
- Aydın, Ö., Tüysüz, M. A. A., & Kılıçaslan, Y. (2007). *Türkçe için bir kelime anlamı belirginleştirme uygulaması* [Bildiri Sunumu]. XII. Elektrik, Elektronik, Bilgisayar, Biyomedikal Mühendisliği Ulusal Kongresi, Eskişehir Osmangazi Üniversitesi, Eskişehir
- Aydoğan, M., & Karci, A. (2019). Kelime Temsil Yöntemleri ile Kelime Benzerliklerinin İncelenmesi. *Çukurova Üniversitesi Mühendislik-Mimarlık Fakültesi Dergisi*, 34(2), 181–196. <https://doi.org/10.21605/cukurovaummfd.609119>
- Barth, D., & Schnell, S. (2021). *Understanding Corpus Linguistics*.
- Baysan, M. S., & Gungor, T. (2025). TR-MTEB: a comprehensive benchmark and embedding model suite for Turkish sentence representations. *Findings of the Association for Computational Linguistics: EMNLP 2025*, 8867–8887. <https://doi.org/10.18653/v1/2025.findings-emnlp.471>
- Civelek, S. (2024). *Passage retrieval on Turkish legal texts using BERT* [Yüksek lisans tezi, Orta Doğu Teknik Üniversitesi]. OpenMETU.

- Devlin, J., Chang, M., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. <https://doi.org/10.18653/v1/N19-1423>
- Du, J., Qi, F., & Sun, M. (2019). Using BERT for word sense disambiguation. *arXiv*. <https://doi.org/10.48550/arXiv.1909.08358>
- Ferrer-i-Cancho, R. (2016). The meaning-frequency law in Zipfian optimization models of communication. *arXiv (Cornell University)*, 35, 28–37. <https://arxiv.org/pdf/1409.7275>
- Garrido-Merchan, E. C., Gozalo-Brizuela, R., & Gonzalez-Carvajal, S. (2023). Comparing BERT against traditional machine learning models in text classification. *Journal of Computational and Cognitive Engineering*, 2(4), 352–356. <https://doi.org/10.47852/bonviewjcce3202838>
- İlgen, B., Adalı, E., & Tantuğ, A. C. (2016). Exploring feature sets for Turkish word sense disambiguation. *Turkish Journal of Electrical Engineering & Computer Sciences*, 24, 4391–4405. <https://doi.org/10.3906/elk-1408-77>
- Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing* (3rd ed. draft). Stanford University.
- Kågebäck, M., & Salomonsson, H. (2016). Word sense disambiguation using a bidirectional LSTM. *arXiv*. <https://doi.org/10.48550/arXiv.1606.03568>
- Krusic, L. (2024). Constructing a Sentiment-Annotated Corpus of Austrian Historical Newspapers: Challenges, Tools, and Annotator Experience. *Proceedings of the 4th International Conference on Natural Language Processing for Digital Humanities*, 51–62. <https://doi.org/10.18653/v1/2024.nlp4dh-1.6>

- Mata, J., Gualda, E., Pachón, V., Rebollo, C., & Domínguez, J. L. (2025). From data to detection: Developing a corpus and training language models for the identification of anti-refugee narratives in Spanish. *Array*, 28, 100526. <https://doi.org/10.1016/j.array.2025.100526>
- Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*.
- Navigli, R. (2009). Word Sense Disambiguation: a survey. *ACM Computing Surveys (CSUR)*, 41(2), 1–69. <https://doi.org/10.1145/1459352.1459355>
- Papineni, K., Roukos, S., Ward, T., & Zhu, W. (2002). Bleu: A Method for Automatic Evaluation of Machine Translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, 311–318. <https://doi.org/10.3115/1073083.1073135>
- Sarıtaş, K., Öz, C. A., & Güngör, T. (2024). A comprehensive analysis of static word embeddings for Turkish. *Expert Systems With Applications*, 252, 124123. <https://doi.org/10.1016/j.eswa.2024.124123>
- Schweter, S. (2020). *BERTurk - BERT models for Turkish* [Yazılım]. Zenodo.
- Wang, Y., Liu, S., Afzal, N., Rastegar-Mojarad, M., Wang, L., Shen, F., Kingsbury, P., & Liu, H. (2018). A comparison of word embeddings for the biomedical natural language processing. *Journal of Biomedical Informatics*, 87, 12–20. <https://doi.org/10.1016/j.jbi.2018.09.008>
- Wiedemann, G., Remus, S., Chawla, A., & Biemann, C. (2019). Does BERT Make Any Sense? Interpretable Word Sense Disambiguation with Contextualized Embeddings. *KONVENS*. https://corpora.linguistik.uni-erlangen.de/data/konvens/proceedings/papers/KONVENS2019_paper_43.pdf

- Xu, W., Napoles, C., Pavlick, E., Chen, Q., & Callison-Burch, C. (2016). Optimizing statistical machine translation for text simplification. *Transactions of the Association for Computational Linguistics*, 4, 401–415.
https://doi.org/10.1162/tacl_a_00107
- Zhao, W., Hu, H., Zhou, W., Shi, J., & Li, H. (2023). BEST: BERT Pre-training for Sign Language Recognition with Coupling Tokenization. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(3), 3597–3605.
<https://doi.org/10.1609/aaai.v37i3.25470>
- Zhu, Y., Zhang, B., Wang, Q. A., Li, W., & Cai, X. (2018). The principle of least effort and Zipf distribution. *Journal of Physics Conference Series*, 1113, 012007.
<https://doi.org/10.1088/1742-6596/1113/1/012007>

EKLER

Ek 1: BERT Mimarisi İnce Ayar Python Betiği

Bu ekte, çalışmanın deneysel aşamasında kullanılan ve dbmdz/bert-base-turkish-cased ön eğitilmiş dil modeli üzerinde gerçekleştirilen ince ayar (fine-tuning) sürecine ait Python betiği sunulmuştur. Kod, 5 eğitim dönemi (epoch) boyunca veri setini sınıflandırma görevine uyarlamakta ve modelin performansını *accuracy* (doğruluk) metriği üzerinden hesaplamaktadır.

```
# --- 1. KURULUMLAR ---
!pip install transformers accelerate -U > /dev/null

import pandas as pd
import torch
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from transformers import AutoTokenizer, AutoModelForSequenceClassification, Trainer,
TrainingArguments

# Model ayarları
DOSYA_ADI = 'el.jsonl' # İlgili dosya adı (örnek: yol.jsonl, bogaz.jsonl)
MODEL_ADI = "dbmdz/bert-base-turkish-cased"

# --- 2. VERİ HAZIRLAMA ---
df = pd.read_json(DOSYA_ADI, lines=True)
df = df.explode('label').dropna(subset=['label'])
df['label'] = df['label'].astype(str)

unique_labels = sorted(df['label'].unique())
label2id = {label: i for i, label in enumerate(unique_labels)}
id2label = {i: label for label, i in label2id.items()}
df['label_id'] = df['label'].map(label2id)

# Veriyi böl (%80 Eğitim, %20 Test)
train_texts, test_texts, train_labels, test_labels = train_test_split(
    df['text'].tolist(), df['label_id'].tolist(), test_size=0.2, random_state=42
)

# --- 3. DATASET VE MODEL ---
class WSDDataset(torch.utils.data.Dataset):
    def __init__(self, encodings, labels):
        self.encodings = encodings
        self.labels = labels

    def __getitem__(self, idx):
        item = {key: torch.tensor(val[idx]) for key, val in self.encodings.items()}
        item['labels'] = torch.tensor(self.labels[idx])
        return item
```

```

def __len__(self):
    return len(self.labels)

def compute_metrics(pred):
    labels = pred.label_ids
    preds = pred.predictions.argmax(-1)
    return {'accuracy': accuracy_score(labels, preds)}

tokenizer = AutoTokenizer.from_pretrained(MODEL_ADI)
model = AutoModelForSequenceClassification.from_pretrained(
    MODEL_ADI, num_labels=len(label2id), id2label=id2label, label2id=label2id
)

train_encodings = tokenizer(train_texts, truncation=True, padding=True, max_length=128)
test_encodings = tokenizer(test_texts, truncation=True, padding=True, max_length=128)

train_dataset = WSDDataset(train_encodings, train_labels)
test_dataset = WSDDataset(test_encodings, test_labels)

# --- 4. EĞİTİM AYARLARI ---
training_args = TrainingArguments(
    output_dir='./sonuclar',
    num_train_epochs=5,
    per_device_train_batch_size=8,
    eval_strategy="epoch",
    report_to="none"
)

trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=train_dataset,
    eval_dataset=test_dataset,
    compute_metrics=compute_metrics,
)

# --- 5. EĞİTİM VE SONUÇ ---
trainer.train()
sonuclar = trainer.evaluate()
print(f"BAŞARI ORANI: %{sonuclar['eval_accuracy']} * 100:.2f}")

```


Ek 2: Etiketlenmiş Veri Seti (JSONL) Örnekleri

Bu ekte, çalışmada odaklanılan çokanlamlı sözcükler ("yol", "el", "boğaz" ve "yüz") için insan gözetiminde hazırlanan ve BERT modelinin ince ayar (fine-tuning) sürecinde kullanılan JSONL formatındaki veri setlerinden kesitler sunulmuştur. Metinler, ilgili hedeflerin bağlamsal farklılıklarını modelin algılayabileceği mikro etiketlerle sınıflandırmaktadır.

“Yol” Sözcüğü Veri Seti Örnekleri

```
{"text": "Sabah erkenden yola çıkarsak trafiğe kalmadan varırız.", "label": ["GUZERGAH"]}  
{"text": "Bu sorunu çözmenin elbet mantıklı bir yolu bulunacaktır.", "label": ["YONTEM"]}  
{"text": "Bahçedeki zararlı otları tek tek eliyle yoldu.", "label": ["FİİL"]}
```

“El” Sözcüğü Veri Seti Örnekleri

```
{"text": "Soğuktan ellerim dondu, hemen eldivenlerimi taktım.", "label": ["ORGAN"]}  
{"text": "Gurbet ellerde yaşamak insana her zaman zor gelir.", "label": ["YABANCI"]}  
{"text": "Akşam kahvehanede bir el tavla attık.", "label": ["OYUN"]}
```

“Boğaz” Sözcüğü Veri Seti Örnekleri

```
{"text": "Soğuk su içtiğim için boğazım çok fena ağrıyor.", "label": ["ORGAN"]}  
{"text": "İstanbul Boğazı'nda harika bir tekne turuna çıktık.", "label": ["COGRAFYA"]}  
{"text": "Kazağın boğazı çok dar olduğu için kafam geçmedi.", "label": ["NESNE"]}
```


“Yüz” Sözcüğü Veri Seti Örnekleri

```
{"text": "Sabah kalktığında ilk iş olarak yüzünü soğuk suyla yıkadı.", "label": ["ORGAN"]}  
{"text": "Sınavdan yüz aldığını duyunca havalara uçtu.", "label": ["SAYI"]}  
{"text": "Hafta sonları formda kalmak için kapalı havuzda yüzer.", "label": ["FİİL_YÜZMEK"]}  
{"text": "Kurban Bayramı'nda kasaplar kesilen hayvanın derisini özenle yüzdüler.", "label": ["FİİL_SOYMAK"]}  
{"text": "Gölün yüzü sabah saatlerinde yoğun bir sis tabakasıyla kaplanmıştı.", "label": ["YÜZEY"]}
```

Ek 3: Veri İşaretleme Aracı (Doccano) Arayüzü ve Etiketleme Süreci

Bu ekte, çalışmanın deneysel aşamalarında kullanılan ve makine öğrenmesi modelleri için yüksek çözünürlüklü eğitim verisi oluşturulmasını sağlayan açık kaynaklı metin işaretleme aracı Doccano'nun arayüzüne ait örnek bir ekran görüntüsü sunulmuştur.

Aşağıdaki görselde, araştırmaya konu olan çokanlamlı hedef sözcüklerin bağlamsal analizinin araştırmacı tarafından arayüz üzerinde nasıl gerçekleştirildiği ve metinlerin mikro düzeydeki anlamsal etiketlerle (somut/soyut ayrımları, sözcük türü kısırlımları vb.) nasıl işaretlendiği görülmektedir. Bu manuel işaretleme aşaması, BERT mimarisinin sözcükler arası anlamsal örüntüleri ezberlemek yerine öğrenebilmesi için kurgulanan "insan gözetiminde etiketleme" stratejisinin temelini oluşturmaktadır.



Şekil 1: Doccano Üzerinden Gerçekleştirilen Örnek Bir Etiketleme İşlemi